

# Relazione Progetto Machine Learning

## 1. Introduzione

### Descrizione del Problema:

Nella presente relazione, esamineremo l'applicazione di diversi algoritmi di machine learning applicati ad una piattaforma di condivisione video. Instagram, una delle piattaforme di social media più popolari al mondo, ha introdotto i Reels, brevi video che possono diventare virali e raggiungere milioni di utenti. Il problema principale affrontato in questo progetto è l'analisi delle metriche chiave dei Reels di Instagram (visualizzazioni, "Mi piace" e commenti) e la predizione dei rapporti tra queste metriche per ottimizzare le strategie di contenuto.

L'obiettivo è dunque comprendere quali fattori influenzino il coinvolgimento degli utenti e quali modelli predittivi possano essere più efficaci per questa previsione.

### Argomento:

L'argomento del progetto è l'analisi dei dati dei Reels di Instagram per identificare tendenze e pattern significativi e sviluppare modelli predittivi che possano stimare i rapporti like/visualizzazioni e commenti/visualizzazioni. Questi rapporti sono cruciali per valutare l'interazione del pubblico con i contenuti.

### Piattaforma:

La piattaforma principale su cui si basa questo progetto è Instagram, un social network focalizzato sulla condivisione di foto e video. I dati sono stati raccolti dai Reels pubblicati dall'account ufficiale di National Geographic, un'istituzione rinomata a livello mondiale per i suoi contenuti di alta qualità riguardanti natura, scienza, cultura e storia. La scelta di National Geographic come fonte di dati è stata motivata dall'alto livello di interazione che i suoi contenuti generano, rendendolo un caso di studio ideale.

### Obiettivo:

L'obiettivo del mio progetto è stato quello di predire attraverso modelli di machine learning il rapporto di like/visualizzazioni o commenti/visualizzazioni prendendo in considerazione delle features precise ovvero:

N. di visualizzazioni, Età del video, Durata e Rapporto commenti/visualizzazioni nel caso del modello di predizione del rapporto like/visualizzazioni, oppure il Rapporto like/visualizzazioni per predire il modello commenti/visualizzazioni.

## 2. Descrizione del Dataset

Il dataset utilizzato per questo progetto comprende i dati dei Reels pubblicati dall'account ufficiale di National Geographic su Instagram. In totale, il dataset contiene informazioni su 400+ Reels. Ogni riga del dataset rappresenta un singolo Reel e le colonne contengono le metriche e le caratteristiche rilevanti per l'analisi (N. di like, N. di commenti, N. di visualizzazioni, Durata del Reel).

### Analisi Descrittiva

Dopo aver raccolto i dati, ho eseguito delle analisi descrittive per comprendere meglio la correlazione tra le varie metriche. Inizialmente, ho estrapolato alcune statistiche descrittive per ogni metrica del dataset, inclusi la media, il valore massimo e minimo, la deviazione standard e i quartili. Questo passaggio mi ha permesso di capire la scala delle metriche e di identificare eventuali differenze significative tra di esse.

Ho notato che le scale delle diverse metriche erano molto diverse tra loro. Per affrontare questo problema e facilitare la visualizzazione comparativa, ho deciso di standardizzare i dati. La standardizzazione è stata particolarmente utile per creare grafici di confronto, come ad esempio i grafici delle serie temporali delle variabili, che hanno reso più evidente l'andamento delle metriche nel tempo.

Successivamente, ho creato una matrice di correlazione per analizzare le relazioni tra le variabili. Da questa matrice è emerso che c'è una maggiore similarità tra visualizzazioni e "Mi piace", dovuta probabilmente a una scala metrica simile. Al contrario, la correlazione più bassa è stata osservata tra commenti e visualizzazioni, evidenziando una differenza significativa tra queste due metriche.

Ho anche trasformato la durata del Reel in secondi, rendendo più semplice lavorare con questa variabile e confrontarla con altre metriche. Utilizzando scatter plot, ho analizzato l'influenza della durata del Reel sul successo dello stesso, misurato in termini di visualizzazioni, "Mi piace" e commenti.

Un'altra analisi interessante ha riguardato l'età del video. Estrapolando la data di pubblicazione di ciascun Reel e calcolando la sua età rispetto alla data attuale, ho creato ulteriori scatter plot per investigare se l'età del video avesse un impatto significativo sulle metriche di successo.

Infine, dividendo i dati per mese, ho realizzato box plot per tutte le variabili estrapolate, organizzati per mese di pubblicazione. Questo mi ha permesso di visualizzare rapidamente se il mese di pubblicazione influenzasse la popolarità del video, osservando le variazioni delle metriche nei diversi periodi dell'anno.

### 3. Algoritmi/Approcci

In questo progetto, ho utilizzato una varietà di algoritmi di machine learning per analizzare e predire il rapporto i like e le visualizzazioni, nonché il rapporto tra i commenti e le visualizzazioni dei reel di Instagram di National Geographic. La scelta degli algoritmi è stata guidata dal desiderio di esplorare diverse tecniche e determinare quale fosse la più efficace nel modellare questi dati. Gli algoritmi utilizzati includono la regressione lineare, la regressione Lasso, gli alberi decisionali, la Random Forest, il Gradient Boosting Machine (GBM) e la Support Vector Regression (SVR).

#### **Regressione Lineare**

La regressione lineare è stata scelta per la sua semplicità e capacità di interpretare facilmente le relazioni tra le variabili indipendenti e la variabile dipendente. Questo algoritmo è utile per identificare se esiste una relazione lineare diretta tra, la durata del video, l'età del video e il numero di visualizzazioni con il rapporto like/visualizzazioni e commenti/visualizzazioni.

#### **Regressione Lasso**

La regressione Lasso è stata impiegata per migliorare il modello lineare introducendo una forma di regolarizzazione che aiuta a evitare il problema dell'overfitting. Questo algoritmo è particolarmente utile quando si lavora con dati che potrebbero contenere molte variabili irrilevanti, poiché tende a ridurre il peso delle caratteristiche meno importanti.

#### **Alberi Decisionali**

Gli alberi decisionali sono stati scelti per la loro capacità di gestire relazioni non lineari e per la loro facilità di interpretazione. Questo algoritmo suddivide i dati in sottoinsiemi omogenei sulla base delle caratteristiche più rilevanti, facilitando l'identificazione di regole decisionali complesse.

## **Random Forest**

Il modello Random Forest è una tecnica ensemble che combina molti alberi decisionali per migliorare la precisione e la robustezza del modello. Questo algoritmo riduce la varianza rispetto ai singoli alberi decisionali e migliora la capacità predittiva complessiva, essendo particolarmente efficace in presenza di dati rumorosi.

## **Gradient Boosting Machine (GBM)**

Il GBM è un altro metodo ensemble che costruisce sequenzialmente alberi decisionali, ciascuno dei quali cerca di correggere gli errori dei precedenti. Questo approccio incrementale rende il GBM particolarmente potente e preciso, anche se può essere più suscettibile all'overfitting rispetto ad altri algoritmi se non è ben regolato.

## **Support Vector Regression (SVR)**

L'SVR è stato utilizzato per la sua capacità di gestire relazioni complesse tra le variabili indipendenti e la variabile dipendente. Questo algoritmo cerca di trovare una funzione che si adatta ai dati entro una certa tolleranza, rendendolo robusto in presenza di outlier e capace di modellare relazioni non lineari.

## **4. Risultati (includere tutte le informazioni, no ripetizioni (stessi risultati ma più rappresentazioni), commento ai risultati**

Per valutare l'efficacia dei modelli di machine learning implementati nel progetto, sono state utilizzate tre metriche principali: l'errore medio assoluto (MAE), la radice dell'errore quadratico medio (RMSE) e il totale degli errori quadrati (TSS). Ognuna di queste metriche fornisce una prospettiva unica sulle prestazioni del modello, permettendo un'analisi completa e dettagliata.

### **MAE (Mean Absolute Error)**

L'errore medio assoluto misura la media delle differenze assolute tra i valori predetti dal modello e i valori reali. È una metrica intuitiva che fornisce una stima diretta dell'errore medio di previsione in unità originali della variabile target. Una MAE più bassa indica che il modello è, in media, più vicino alle osservazioni reali.

### **RMSE (Root Mean Squared Error)**

La radice dell'errore quadratico medio è una metrica che amplifica gli errori maggiori, poiché le differenze tra i valori predetti e quelli reali vengono elevate al quadrato prima di essere mediate. Successivamente, viene calcolata la radice quadrata di questa media. L'RMSE è utile per capire quanto i grandi errori influenzino le prestazioni del modello. Un valore più basso di RMSE indica una maggiore precisione del modello.

## Risultati dei Modelli

### Regressione Lineare

- Rapporto Like/Visualizzazioni
  - RMSE: 14395.15
  - MAE: 10971.61
- Rapporto Commenti/Visualizzazioni
  - RMSE: 132.91
  - MAE: 82.59

### Regressione Lasso

- Rapporto Like/Visualizzazioni
  - RMSE: 14289.05
  - MAE: 10885.23
- Rapporto Commenti/Visualizzazioni
  - RMSE: 132.30
  - MAE: 77.80

### Random Forest

- Rapporto Like/Visualizzazioni
  - RMSE: 13701.48
  - MAE: 9187.95
- Rapporto Commenti/Visualizzazioni
  - RMSE: 140.95
  - MAE: 81.32

### Gradient Boosting Machine (GBM)

- Rapporto Like/Visualizzazioni
  - RMSE: 14311.19
  - MAE: 9254.94
- Rapporto Commenti/Visualizzazioni
  - RMSE: 137.46
  - MAE: 79.24

### Support Vector Regression (SVR)

- Rapporto Like/Visualizzazioni
  - RMSE: 16033.44
  - MAE: 10780.13
- Rapporto Commenti/Visualizzazioni
  - RMSE: 151.02
  - MAE: 72.88

### Decision Tree

- Rapporto Like/Visualizzazioni
  - RMSE: 21687.23
  - MAE: 13244.67
- Rapporto Commenti/Visualizzazioni
  - RMSE: 223.61
  - MAE: 106.8

## Commento ai Risultati

**Regressione Lineare e Lasso:** Questi modelli hanno fornito una base solida di confronto, mostrando performance ragionevoli per entrambe le variabili target. La regressione Lasso ha ulteriormente migliorato i risultati riducendo l'overfitting grazie alla regolarizzazione.

**Random Forest:** Il modello Random Forest ha mostrato buone prestazioni, specialmente per il rapporto like/visualizzazioni, con valori di MAE e RMSE inferiori rispetto ad altri modelli lineari. Questo indica che la Random Forest è efficace nel catturare le complesse relazioni non lineari presenti nel dataset.

**Gradient Boosting Machine (GBM):** Il Gradient Boosting Machine ha offerto prestazioni eccellenti, dimostrando una notevole capacità di modellare relazioni complesse nei dati. Tuttavia, i valori di RMSE e MAE non si sono discostati significativamente dagli altri modelli ensemble, indicando che potrebbe essere necessario un ulteriore tuning per migliorare le prestazioni.

**Support Vector Regression (SVR):** La Support Vector Regression ha mostrato buone capacità predittive, soprattutto per modelli non lineari, ma i valori di RMSE e MAE sono risultati essere più elevati rispetto ad altri modelli. Questo suggerisce che l'SVR potrebbe non essere il miglior approccio per questo dataset specifico senza ulteriori ottimizzazioni.

**Decision Tree:** Gli alberi decisionali, nonostante la loro semplicità e interpretabilità, hanno mostrato una maggiore variabilità negli errori. Con valori di RMSE e MAE superiori, questo modello ha dimostrato di essere meno efficace nel predire le variabili target rispetto ai modelli ensemble e regolarizzati.


I risultati dei modelli presentano valori molto diversi tra loro, e ciò è dovuto alla grande differenza di scala nei dati di input. Questo è evidenziato dalla media dei rapporti tra like/visualizzazioni e commenti/visualizzazioni, che sono rispettivamente:

- Media del rapporto like/visualizzazioni: 22934.91
- Media del rapporto commenti/visualizzazioni: 134.30

Questa disparità nelle unità di grandezza influisce sulle metriche di errore, rendendo i valori di MAE e RMSE molto diversi tra i due rapporti. Le differenze nei valori medi indicano che il numero di like è significativamente maggiore rispetto al numero di commenti, influenzando di conseguenza le metriche di valutazione dei modelli.

## 5. Conclusioni (analisi sintetica)


In base ai risultati ottenuti, possiamo trarre diverse conclusioni riguardo l'efficacia degli algoritmi di machine learning nel predire i rapporti like/visualizzazioni e commenti/visualizzazioni dei reel di National Geographic su Instagram.



L'algoritmo **Random Forest** si è dimostrato il più performante secondo la metrica dell'RMSE per la predizione del rapporto like/visualizzazioni, con un valore di RMSE di 13701.48. Questo indica che il modello è in grado di prevedere il rapporto like/visualizzazioni con una maggiore precisione rispetto agli altri algoritmi considerati. La capacità del Random Forest di gestire complessità non lineari e interazioni tra variabili ha permesso di ottenere previsioni più accurate.


Gli algoritmi di **Gradient Boosting Machine (GBM)** e **Regressione Lasso** hanno ottenuto risultati comparabili, con valori di RMSE poco superiori rispetto al Random Forest. Il **GBM**, con un RMSE di 14311.19, e la **Regressione Lasso**, con un RMSE di 14289.05, rappresentano valide alternative al Random Forest. Entrambi questi modelli offrono un buon compromesso tra accuratezza e interpretabilità, rendendoli utili in scenari dove il **Random Forest** potrebbe non essere la scelta ottimale per motivi di complessità computazionale o interpretabilità del modello.

Il **Decision Tree** e l'algoritmo di **Support Vector Regression (SVR)** hanno ottenuto i risultati peggiori per la predizione del rapporto like/visualizzazioni. Il **Decision Tree** ha registrato un RMSE molto elevato di 21687.23, evidenziando la sua limitata capacità di generalizzazione su questo dataset. **L'SVR**, con un RMSE di 16033.44, ha mostrato anch'esso una performance inferiore rispetto agli altri algoritmi. Questi risultati




suggeriscono che né il **Decision Tree** né l'**SVR** sono adatti per questo specifico problema di previsione.

Anche considerando la metrica del MAE, l'algoritmo **Random Forest** si è dimostrato il più performante, con un valore di MAE di 9187.95, seguito da vicino dal GBM, che ha registrato un MAE di 9254.94. Questi valori indicano che entrambi gli algoritmi sono molto precisi nel prevedere il rapporto like/visualizzazioni, con il **Random Forest** leggermente in vantaggio. Il **Decision Tree**, ancora una volta, ha mostrato le peggiori performance con un MAE di 13244.67, confermando la sua inadeguatezza per questo compito. Per quanto riguarda invece il rapporto tra commenti/visualizzazioni, la metrica dell'RMSE evidenzia una maggiore accuratezza per quanto riguarda gli algoritmi di **Regressione Lasso e Lineare**.



Per quanto riguarda la predizione del rapporto commenti/visualizzazioni, le metriche dell'RMSE indicano che gli algoritmi di **Regressione Lasso e Regressione Lineare** sono i più accurati. La **Regressione Lasso** ha ottenuto un RMSE di 132.30, mentre la **Regressione Lineare** ha registrato un RMSE di 132.91. Questi risultati suggeriscono che entrambi gli algoritmi lineari sono ben adatti a catturare le dinamiche del rapporto commenti/visualizzazioni, probabilmente grazie alla natura più lineare e meno complessa di questo rapporto rispetto ai like.



Considerando la metrica del MAE, l'algoritmo di **Support Vector Regression (SVR)** si è rivelato il più accurato per la predizione del rapporto commenti/visualizzazioni, con un valore di MAE di 72.88. Questo risultato, combinato con un RMSE più alto, suggerisce che l'**SVR** è particolarmente efficace nel ridurre gli errori medi, anche se è influenzato negativamente dagli errori più grandi. Gli algoritmi di **Regressione Lasso e GBM** seguono con valori di MAE leggermente superiori, rispettivamente 77.80 e 79.24, indicando che sono anch'essi buone alternative.

Ancora una volta, il **Decision Tree** ha mostrato le peggiori performance, con un RMSE di 223.61 e un MAE di 106.84. Questi risultati confermano la limitata capacità del **Decision Tree** di gestire la variabilità e la complessità dei dati, rendendolo inadeguato per la predizione del rapporto commenti/visualizzazioni.

In conclusione, il **Random Forest** emerge come l'algoritmo più efficace per la predizione del rapporto like/visualizzazioni, mentre per il rapporto commenti/visualizzazioni, la **Regressione Lasso e l'SVR** si dimostrano le scelte migliori a seconda della metrica considerata. Gli algoritmi di **Decision Tree**, in entrambi i casi, non risultano adatti per questo tipo di predizioni, indicando che la loro semplicità non riesce a catturare adeguatamente le caratteristiche complesse dei dati dei reel di National Geographic su Instagram.